TESSAN x Snowflake Hackathon

Détection des Maladies Respiratoires
par Analyse de Sons Respiratoires

🏥 Cabines médicales connectées • 🩺 Télémédecine • 🧠 Intelligence Artificielle

• Asthme • BPCO • Bronchique • Pneumonie

Dataset : Asthma Detection Dataset Version 2 (Kaggle)

Partie 1 : Présentation de Tessan

Qui sommes-nous ?

Tessan est une entreprise française spécialisée dans la télémédecine et la santé connectée. Notre mission est de réduire les inégalités d'accès aux soins en déployant des cabines médicales connectées directement dans les pharmacies et les établissements de santé (EHPAD, résidences seniors).

Ces cabines permettent à tout patient de réaliser une téléconsultation complète avec un médecin, accompagnée de mesures physiologiques en temps réel grâce à des dispositifs médicaux intégrés (thermomètre, tensiomètre, oxymètre, stéthoscope connecté, otoscope et dermatoscope).

Tessan en chiffres

Indicateur	Valeur
Cabines déployées	1 600+
Médecins partenaires	350+
Points d'implantation	Pharmacies, EHPAD, résidences seniors, Mairie
Dispositifs médicaux intégrés	Thermomètre, tensiomètre, oxymètre, stéthoscope, otoscope, dermatoscope
Couverture géographique	France métropolitaine

Notre mission

La France fait face à une crise majeure de l'accès aux soins. Près de 6 millions de Français vivent dans des déserts médicaux, sans accès rapide à un médecin généraliste. Les délais de consultation s'allongent, les urgences sont surchargées, et les patients les plus vulnérables (personnes âgées, personnes à mobilité réduite) sont les plus touchés.

Tessan répond à ce défi en rapprochant la médecine du patient : nos cabines installées en pharmacie transforment chaque officine en véritable point de soin de proximité, accessible sans rendez-vous, 7j/7.

Pourquoi l'IA chez Tessan ?

Avec plus de 1 500 cabines déployées, Tessan génère un volume considérable de données médicales (capteurs, consultations, retours patients). L'intelligence artificielle représente une opportunité unique pour :

- Améliorer le pré-screening des patients avant la téléconsultation.
- Détecter précocement des pathologies grâce à l'analyse de signaux biométriques.
- Optimiser le triage et orienter les patients vers le bon parcours de soin.
- Réduire la charge sur les médecins en automatisant les analyses préliminaires.

C'est dans ce contexte que s'inscrit ce hackathon : explorer comment les sons respiratoires peuvent devenir un outil de diagnostic assisté par IA, directement intégré dans nos cabines connectées.

Partie 2 : Problématique du Hackathon

Objectif du challenge

Vous êtes une équipe de data scientists / ingénieurs IA. Votre mission est de concevoir un système de détection des maladies respiratoires à partir de sons de respiration (auscultation pulmonaire), en utilisant l'écosystème Snowflake comme plateforme de données et de déploiement.

Scénario :

Un patient entre dans une cabine Tessan en pharmacie. Le pharmacien place le stéthoscope connecté sur le thorax du patient. Le système IA analyse les sons respiratoires en temps réel et fournit au médecin un pré-diagnostic :

- Probabilité d'asthme : 62%
- Probabilité de BPCO : 18%
- Probabilité de pneumonie : 10%
- Probabilité de bronchique : 7%
- Patient sain : 3%

Maladies ciblées

Ce hackathon se concentreBsur la détection de maladies respiratoires via l'analyse de sons de respiration (auscultation). Les pathologies visées correspondent aux 5 classes du dataset :

Maladie	Signatures respiratoires	Pourquoi la détecter ?
Asthme	Sifflements expiratoires (wheezing), respiration sifflante, obstruction bronchique audible	Maladie chronique très fréquente, 4 millions de Français touchés, monitoring essentiel
BPCO	Sifflements, crépitements, diminution du murmure vésiculaire, expiration prolongée	3ème cause de mortalité mondiale, souvent sous-diagnostiquée, détection précoce critique
Bronchique	Râles bronchiques, respiration bruyante, ronchi (sons graves continus), encombrement	Inflammation des bronches nécessitant un traitement adapté pour éviter les complications
Pneumonie	Crépitements fins (crackles), souffle tubaire, respiration rapide et superficielle	Urgence médicale, 1ère cause de mortalité infectieuse, détection précoce vitale
Sain	Murmure vésiculaire régulier, pas de sifflements, pas de crépitements, rythme normal	Classe de référence indispensable pour la classification

Dataset utilisé : Asthma Detection Dataset Version 2

Source	Kaggle – Mohammed Tawfik Musaed
Taille	1 211 échantillons audio de sons respiratoires
Format	WAV (fréquences d'échantillonnage et durées hétérogènes)
Classes (5)	Asthma, COPD, Bronchial, Pneumonia, Healthy
Type de signal	Sons respiratoires (auscultation pulmonaire au stéthoscope)
Accès	Ouvert : kaggle.com/datasets/mohammedtawfikmusaed/asthma-detection-dataset-version-2
Benchmark	~91% accuracy, 0.90 macro F1-score, 0.99 macro ROC-AUC (CNN-BiLSTM-Attention)

Distribution des classes :

Le dataset présente un déséquilibre entre les classes. La classe BPCO est la plus représentée, tandis que la classe Bronchique est la plus rare. Ce déséquilibre devra être pris en compte dans votre approche.

Biomarqueurs respiratoires à exploiter

Les sons respiratoires portent des signatures acoustiques spécifiques à chaque pathologie. Voici les biomarqueurs clés que votre modèle devra apprendre à distinguer :

- **Sifflements vs crépitements :** pattern acoustique distinct entre respiration sifflante (asthme) et crépitements (pneumonie)
- **Murmure vésiculaire altéré :** diminution de l'amplitude du murmure vésiculaire, expiration anormalement prolongée
- **Râles et ronchi :** sons graves continus (ronchi) liés à l'encombrement bronchique, râles humides
- **Patterns temporels :** rapport inspiration/expiration anormal, fréquence respiratoire élevée ou irrégulière
- **Patterns spectraux :** signatures fréquentielles distinctes dans les spectrogrammes Mel des cycles respiratoires

Pipeline technique attendu

Acquisition	Prétraitement	Mel-Spectro	CNN/ResNet	Classification	Résultat
Sons respiratoires WAV	Resampling, normalisation, segmentation, filtrage bruit	Extraction Mel-spectrogrammes + MFCC	Feature extraction deep learning	5 classes : Asthme / BPCO / Bronchique / Pneumonie / Sain	Probabilités + recommandation clinique

Stack technique recommandée

Traitement audio	librosa, torchaudio, scipy.signal
Feature extraction	Mel-spectrogrammes, MFCC, Chroma, Spectral Centroid, Zero-Crossing Rate

Modèles ML/DL	PyTorch ou TensorFlow (CNN, ResNet, CNN-BiLSTM, Attention), scikit-learn
Plateforme données	Snowflake (stockage, Snowpark Python, Stages)
Interface	Streamlit (démo interactive)

Livrables attendus

1. **Modèle entraîné** capable de classifier un son respiratoire en Asthme / BPCO / Bronchique / Pneumonie / Sain
2. **Pipeline de données** dans Snowflake (ingestion des WAV, extraction des features, stockage structuré)
3. **Application Streamlit** permettant d'uploader un son respiratoire et de recevoir un diagnostic en temps réel
4. **Présentation** de votre approche, résultats et perspectives d'intégration dans les cabines Tessan

Partie 3 : Questions guidées

Ces questions sont conçues pour vous accompagner pas à pas. Suivez-les dans l'ordre pour construire progressivement votre solution.

Phase 1 : Compréhension et exploration des données

Q1. **Téléchargez le dataset « Asthma Detection Dataset Version 2 » depuis Kaggle et chargez-le dans Snowflake. Comment structurez-vous vos tables pour stocker les métadonnées (classe, durée, sample rate) et les fichiers audio WAV ?**

Indice : utilisez un Snowflake Stage pour les fichiers WAV et une table structurée pour les métadonnées. La commande PUT permet d'uploader les fichiers vers un stage interne.

Q2. **Explorez la distribution des 5 classes (Asthma, COPD, Bronchial, Pneumonia, Healthy). Y a-t-il un déséquilibre ? Quelle classe est sous-représentée ? Comment allez-vous gérer ce déséquilibre ?**

Indice : la classe Bronchial est la plus rare du dataset. Pensez à SMOTE, oversampling, class weights, ou data augmentation audio. Visualisez la distribution avec un bar chart.

Q3. **Analysez les propriétés audio de vos fichiers : quelles sont les durées, fréquences d'échantillonnage, et amplitudes ? Y a-t-il de la variabilité ? Pourquoi est-ce important de normaliser ces paramètres ?**

Indice : le dataset contient des WAV avec des sampling rates et durées hétérogènes. Utilisez librosa.load() pour inspecter chaque fichier et créez des statistiques descriptives.

Q4. **Écoutez quelques échantillons de chaque classe. Quelles différences percevez-vous entre un sifflement asthmatique, les crépitements d'une pneumonie, et une respiration saine ?**

Indice : cette étape qualitative est essentielle. Visualisez les formes d'onde et spectrogrammes côte à côte pour chaque classe avec librosa.display.

Phase 2 : Prétraitement et extraction de features

Q5. **Standardiser tous vos fichiers audio : quel sample rate cible choisissez-vous ? Quelle durée fixe ? Comment gérez-vous les enregistrements trop courts ou trop longs ?**

Indice : resamplez tous les fichiers à 22 050 Hz. Pour la durée, segmentez en fenêtres fixes (ex. 4-6 secondes). Les fichiers courts sont paddés avec du silence, les longs sont cropés ou découpés en segments.

Q6. **Convertissez vos fichiers audio en spectrogrammes Mel. Quels paramètres choisissez-vous (n_mels, n_fft, hop_length) et pourquoi ? Quelle est la différence visuelle entre un spectrogramme d'asthme et un de BPCO ?**

Indice : librosa.feature.melspectrogram() avec sr=22050, n_mels=128, n_fft=2048, hop_length=512 sont des valeurs de départ classiques. Convertissez en dB avec librosa.power_to_db() pour une meilleure visualisation.

Q7. **Quelles features acoustiques supplémentaires extrayez-vous ? (MFCC, Spectral Centroid, Spectral Bandwidth, Zero-Crossing Rate, Chroma). Lesquelles sont les plus discriminantes pour les sons respiratoires ?**

Indice : les MFCC (13-20 coefficients) capturent l'enveloppe spectrale. Le Spectral Centroid aide à distinguer les sons aigus (sifflements) des sons graves (ronchi). Le ZCR détecte le bruit de fond.

Q8. **Comment filtrez-vous le bruit de fond et les artefacts (bruits de manipulation du stéthoscope, respiration du soignant) ? Quelle stratégie de nettoyage appliquez-vous ?**

Indice : appliquez un filtre passe-bande (100-2000 Hz) pour isoler les sons pulmonaires pertinents. Utilisez scipy.signal.butter() pour le filtrage et librosa.effects.trim() pour supprimer les silences.

Phase 3 : Modélisation et entraînement

Q9. **Concevez votre architecture. Partez-vous d'un CNN simple sur les spectrogrammes Mel, ou utilisez-vous une architecture plus avancée (CNN-BiLSTM, ResNet, Attention) ? Justifiez votre choix.**

Indice : un CNN simple est un bon point de départ (baseline). Pour aller plus loin, un CNN-BiLSTM avec attention capte à la fois les patterns spatiaux (CNN) et temporels (BiLSTM) des cycles respiratoires. Le benchmark du dataset utilise cette approche et atteint ~91% d'accuracy.

Q10. **Comment divisez-vous vos données en train/validation/test ? Pourquoi un split stratifié par classe est-il crucial vu le déséquilibre du dataset ?**

Indice : utilisez sklearn.model_selection.StratifiedShuffleSplit pour garantir que chaque split contient la même proportion de chaque classe. Un ratio 70/15/15 est recommandé.

Q11. **Quelles métriques utilisez-vous pour évaluer votre modèle ? Pourquoi l'accuracy seule est insuffisante dans un contexte médical avec des classes déséquilibrées ?**

Indice : utilisez le macro F1-score (qui pondère également chaque classe), l'AUC-ROC par classe, la matrice de confusion, et la sensibilité (recall). En médecine, un faux négatif (manquer une pneumonie) est plus grave qu'un faux positif.

Q12. **Appliquez de la data augmentation audio pour améliorer la robustesse. Quelles techniques utilisez-vous ?**

Indice : time stretching, pitch shifting, ajout de bruit gaussien, SpecAugment (masquage de bandes fréquentielles/temporelles sur le spectrogramme). Ces techniques sont cruciales pour un dataset de 1 211 échantillons.

Phase 4 : Déploiement Snowflake

Q13. **Déployez votre modèle dans Snowflake. Créez une UDF (User-Defined Function) Snowpark Python qui prend un fichier audio en entrée et retourne les probabilités pour chaque classe.**

Indice : Snowpark permet d'exécuter du code Python avec des packages comme librosa et torch directement dans Snowflake. Créez une UDF qui charge le modèle depuis un Stage et effectue l'inférence.

Q14. **Construisez une application Streamlit qui permet d'uploader un son respiratoire et d'afficher le diagnostic. Quels éléments d'interface sont essentiels pour un médecin ?**

Indice : affichez le spectrogramme Mel du son, un graphique radar/barre des probabilités par classe, un niveau de confiance, une recommandation d'action (consultation urgente, suivi, etc.), et permettez la comparaison avec des sons de référence.

Q15. **Comment stockez-vous les résultats de prédiction dans Snowflake pour créer un dashboard de surveillance épidémiologique à l'échelle du réseau Tessan ?**

Indice : créez une table PREDICTIONS avec timestamp, pharmacie_id, classe_predite, probabilites, confiance. Cela permettrait de détecter en temps réel des pics d'asthme ou de pneumonie par région.

Phase 5 : Bonus et perspectives

Q16. **L'explicabilité est essentielle en médecine. Comment montrez-vous au médecin POURQUOI le modèle a fait telle prédiction ? Quelles zones du spectrogramme ont été déterminantes ?**

Indice : utilisez Grad-CAM sur les spectrogrammes pour visualiser les régions fréquentielles/temporelles les plus influentes. SHAP peut expliquer l'importance de chaque feature acoustique.

Q17. **Imaginez l'intégration complète dans une cabine Tessan. Comment combineriez-vous les sons respiratoires du stéthoscope avec les autres capteurs (oxymètre: SpO2, thermomètre: température, tensiomètre) pour un diagnostic multimodal ?**

Indice : un modèle de fusion multimodal (late fusion) pourrait combiner les features audio avec SpO2 < 95%, fièvre > 38°C, fréquence cardiaque élevée pour une précision nettement améliorée.

Critères d'évaluation

Critère	Points	Détails
Qualité du pipeline de données	**20 pts**	Ingestion des WAV, nettoyage, structuration dans Snowflake
Feature engineering audio	**20 pts**	Pertinence des features (Mel, MFCC, etc.), prétraitement
Performance du modèle	**25 pts**	Métriques (AUC, F1 macro, recall), généralisation
Intégration Snowflake	**15 pts**	Snowpark UDFs, Stages, Streamlit
Démo & présentation	**10 pts**	Clarté de la démo Streamlit, storytelling
Innovation & perspectives	**10 pts**	Explicabilité (Grad-CAM/SHAP), fusion multimodale, idées
TOTAL	**100 pts**	

Bonne chance à tous les participants !

N'hésitez pas à expérimenter et à penser à l'impact réel de votre solution sur les patients. Avec le stéthoscope connecté des cabines Tessan et l'IA, vous construisez peut-être le futur du diagnostic respiratoire de proximité.